Acara X

Pokok Bahasan : Clustering
Minggu / Acara : 3 / 1
Tempat : PSDKU Sidoarjo
Alokasi Waktu : 4 x 110 menit

a. Indikator

1. Mahasiswa mampu menjelaskan klastering
2. Mahasiswa mampu memahami klastering
3. Mahasiswa mampu menyelesaikan studi kasus tentang klastering

b. Dasar Teori

Clustering adalah teknik dalam machine learning yang digunakan untuk mengelompokkan data berdasarkan kemiripan karakteristiknya. Data yang memiliki karakteristik serupa akan ditempatkan dalam kelompok yang sama, sedangkan data yang karakteristiknya berbeda cenderung ditempatkan dalam kelompok yang berbeda.

Clustering termasuk salah satu metode unsupervised learning atau pembelajaran tanpa pengawasan. Artinya, data yang digunakan tidak harus memiliki label kelas sejak awal. Misalnya, terdapat data 10 mahasiswa. Kemudian ingin mengetahui apakah mahasiswa tersebut dapat dikelompokkan berdasarkan nilai akademik dan persentase kehadirannya. Sebelum clustering, kita belum mengetahui kelompok setiap mahasiswa. Algoritma K-Means akan membantu menemukan kelompok berdasarkan pola data tersebut.

1. Algoritma K-Means

K-Means adalah algoritma clustering yang membagi sekumpulan data menjadi Kkelompok berdasarkan kedekatan data terhadap pusat kelompoknya. Pusat kelompok tersebut disebut **centroid**. Contohnya, jika ingin membagi mahasiswa menjadi tiga kelompok, kita menetapkan:

$$K = 3$$

Algoritma kemudian berusaha membentuk tiga kelompok berdasarkan kemiripan nilai akademik dan kehadiran mahasiswa. Hasil kelompok tersebut tidak otomatis memiliki nama seperti "baik", "sedang", atau "kurang". Nama kelompok ditentukan setelah kita memeriksa karakteristik centroid dan data anggotanya.

Centroid adalah titik pusat suatu kelompok yang dihitung berdasarkan rata-rata nilai setiap fitur dari seluruh data yang menjadi anggotanya. Misalnya, terdapat tiga data dengan nilai akademik:

$$70, 80, 90$$

Centroid untuk fitur nilai akademik adalah:

$$C = \frac{70 + 80 + 90}{3}$$

$$\boxed{C = 80}$$

Jika data memiliki dua fitur, centroid memiliki dua koordinat. Misalnya, fitur nilai akademik dan kehadiran:

Data	Nilai	Kehadiran
A	70	80
B	80	90
C	90	100

Centroidnya adalah:

$$C_{\text{nilai}} = \frac{70 + 80 + 90}{3} = 80$$

$$C_{\text{kehadiran}} = \frac{80 + 90 + 100}{3} = 90$$

Jadi, koordinat centroid:

$$\boxed{C = (80, 90)}$$

Centroid dapat dibayangkan sebagai titik pusat yang mewakili karakteristik rata-rata anggota kelompok.

2. Cara Kerja Algoritma K-Means

1) Menentukan jumlah cluster

   Tentukan banyak kelompok yang ingin dibentuk.

   Misalnya:

   $$K = 3$$

   Artinya, algoritma akan membentuk tiga cluster.

2) Menentukan centroid awal

   Algoritma memilih tiga titik awal sebagai pusat cluster. Centroid awal dapat dipilih secara acak atau menggunakan metode inisialisasi seperti K-Means++. Pemilihan centroid awal dapat memengaruhi hasil clustering.

3) Menghitung jarak setiap data

   Setiap data dihitung jaraknya terhadap masing-masing centroid. Pada K-Means standar, jarak Euclidean umum digunakan.

4) Menentukan cluster setiap data

Data dimasukkan ke cluster dengan centroid terdekat.

5) Menghitung ulang centroid

Setelah semua data mendapatkan cluster, centroid dihitung kembali menggunakan rata-rata seluruh anggota cluster.

6) Mengulangi proses

Algoritma kembali menghitung jarak dan menentukan keanggotaan cluster menggunakan centroid terbaru.

Proses berulang sampai kondisi berhenti tercapai, misalnya:

- Keanggotaan cluster tidak berubah lagi.
- Perubahan centroid sudah sangat kecil.
- Jumlah iterasi maksimum tercapai.

3. Rumus Jarak Euclidean

Untuk menentukan centroid terdekat, K-Means menghitung jarak antara data dan centroid. Jika terdapat dua fitur, rumus jarak Euclidean adalah:

$$\boxed{d(x,c) = \sqrt{(x_1 - c_1)^2 + (x_2 - c_2)^2}}$$

Keterangan:

- x_1: fitur pertama pada data.
- x_2: fitur kedua pada data.
- c_1: koordinat pertama centroid.
- c_2: koordinat kedua centroid.
- $d(x,c)$: jarak antara data dan centroid.

Untuk data dengan $n$fitur, rumus umumnya:

$$\boxed{d(x,c) = \sqrt{\sum_{j=1}^{n} (x_j - c_j)^2}}$$

Semakin kecil nilai jarak, semakin dekat data tersebut dengan centroid.

Contoh perhitungan

Diketahui data mahasiswa:

$$X = (80, 90)$$

Dua centroid:

$$C_1 = (70, 80)$$
$$C_2 = (85, 95)$$

Hitung jarak data Xke C_1:

$$d(X, C_1) = \sqrt{(80 - 70)^2 + (90 - 80)^2}$$
$$= \sqrt{10^2 + 10^2}$$
$$= \sqrt{200}$$
$$\boxed{d(X, C_1) \approx 14{,}14}$$

Sekarang hitung jarak ke C_2:

$$d(X, C_2) = \sqrt{(80 - 85)^2 + (90 - 95)^2}$$
$$= \sqrt{(-5)^2 + (-5)^2}$$
$$= \sqrt{50}$$
$$\boxed{d(X, C_2) \approx 7{,}07}$$

Bandingkan hasilnya:

Centroid	Jarak
C_1	14,14
C_2	7,07

Karena jarak ke C_2lebih kecil, data mahasiswa tersebut masuk ke cluster yang diwakili oleh C_2. Data ditempatkan pada cluster dengan centroid terdekat, bukan centroid terjauh.

c. Alat dan Bahan

1. BKPM
2. Alat tulis
3. Folio Bergaris / HVS

d. Prosedur Kerja

Praktek Menggunakan Excel

1) Memasukkan dataset ke excel

Masukkan data berikut pada Sheet Data.

Mahasiswa	Nilai Akademik	Kehadiran
M1	60	65
M2	65	70
M3	70	75

M4	80	85
M5	85	90
M6	90	95

2) Standardisasai data (Z-Score)

Standardisasi diperlukan agar skala nilai akademik dan kehadiran tidak mendominasi perhitungan jarak.

Rumus Z-Score:

$$Z = \frac{X - \mu}{\sigma}$$

Keterangan:

- X = nilai data.
- μ = nilai rata-rata.
- σ = standar deviasi.

Buat Sheet Standardisasi.

Menghitung Rata-Rata:

Misalnya:

Sel	Rumus Excel
B2	=AVERAGE(Data!B2:B7)
C2	=AVERAGE(Data!C2:C7)

Hasil:

- Rata-rata akademik = 75
- Rata-rata kehadiran = 80

Menghitung standar deviasi populasi

Sel	Rumus Excel
B3	=STDEV.P(Data!B2:B7)
C3	=STDEV.P(Data!C2:C7)

Menghitung Z-Score

Buat tabel:

Mahasiswa	Z Akademik	Z Kehadiran
M1	Rumus	Rumus
M2	Rumus	Rumus
M3	Rumus	Rumus
M4	Rumus	Rumus
M5	Rumus	Rumus
M6	Rumus	Rumus

Untuk M1, gunakan:

Z Akademik (B6):

=(Data!B2-$B$2)/$B$3

Z Kehadiran (C6):

=(Data!C2-$C$2)/$C$3

Tarik kedua rumus sampai baris M6.

3) Menentukan Centroid Awal

Karena menggunakan K = 2, kita membutuhkan dua centroid awal.

Sebagai contoh, kita pilih:

- Centroid C1 = M1
- Centroid C2 = M6

Centroid diambil dari data yang sudah distandardisasi.

Centroid	Z Akademik	Z Kehadiran
C1	Nilai M1	Nilai M1
C2	Nilai M6	Nilai M6

Pemilihan ini hanya contoh untuk pembelajaran. Dalam praktik, centroid juga dapat dipilih secara acak atau menggunakan K-Means++.

4) Menghitung Jarak Euclidean

Rumus jarak Euclidean:

$$d(x, c) = \sqrt{(x_1 - c_1)^2 + (x_2 - c_2)^2}$$

Misalnya M1 terhadap centroid C1: =SQRT((B6-$B$2)^2+(C6-$C$2)^2)

M1 terhadap centroid C2: =SQRT((B6-$B$3)^2+(C6-$C$3)^2)

Keterangan:

- B6 = Z Akademik mahasiswa M1.
- C6 = Z Kehadiran mahasiswa M1.
- B2 dan C2 = koordinat centroid C1.
- B3 dan C3 = koordinat centroid C2.

Buat tabel perhitungan:

Mahasiswa	Jarak ke C1	Jarak ke C2
M1	Rumus	Rumus
M2	Rumus	Rumus
M3	Rumus	Rumus
M4	Rumus	Rumus
M5	Rumus	Rumus
M6	Rumus	Rumus

5) Menentukan Anggota Cluster

Mahasiswa masuk ke cluster dengan jarak paling kecil.

Misalnya:

- Jarak C1 = 0,5
- Jarak C2 = 2,5

Maka mahasiswa masuk Cluster 1.

Rumus Excel: =IF(B2<C2,"C1","C2")

Asumsikan B2 adalah jarak ke C1 dan C2 adalah jarak ke C2.

6) Menghitung Centroid Baru

Setelah seluruh mahasiswa memperoleh cluster, hitung rata-rata setiap fitur dalam masing-masing cluster.

Misalnya tabel hasil clustering berada pada Sheet Iterasi 1:

Mahasiswa	Z Akademik	Z Kehadiran	Cluster
M1	...	...	C1
M2	...	...	C1
M3	...	...	C1
M4	...	...	C2
M5	...	...	C2
M6	...	...	C2

Rumus centroid baru C1 untuk Z Akademik: =AVERAGEIF(D2:D7,"C1",B2:B7)

Rumus centroid baru C1 untuk Z Kehadiran: =AVERAGEIF(D2:D7,"C1",C2:C7)

7) Melakukan iterasi berikutnya

Setelah centroid baru diperoleh:

1. Hitung ulang jarak seluruh mahasiswa ke C1 dan C2.
2. Tentukan kembali anggota cluster.
3. Hitung kembali centroid.
4. Bandingkan hasil cluster sebelumnya dengan hasil cluster terbaru.

K-Means berhenti ketika keanggotaan cluster tidak berubah lagi (konvergen), atau ketika batas iterasi yang ditentukan tercapai.

Praktek Menggunakan Python

1) Memasukkan dataset ke excel

Mahasiswa	Nilai Akademik	Kehadiran
M1	60	65
M2	65	70
M3	70	75
M4	80	85
M5	85	90
M6	90	95

Masukkan data berikut pada Sheet Data dan simpan menjadi file .csv/xlsx.

2) Proses Menggunakan Kode Python Berikut

```
# import library
import os
os.environ["OMP_NUM_THREADS"] = "1"

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler



# ubah file csv menjadi dataframe
df = pd.read_csv('mahasiswa.csv')

# tampilkan 3 baris pertama
df.head(3)
```

```
# ubah nama kolom
df = df.rename(columns={'Mahasiswa': 'mahasiswa',
                        'Nilai akademik': 'nilai_akademik',
                        'Kehadiran (%)': 'kehadiran'})



# tampilkan data yang sudah di preprocess
```

```
df.head(3)
```

```
# menghilangkan kolom customer id dan gender
X = df.drop(['mahasiswa'], axis=1)

# membuat list yang berisi inertia
clusters = []
for i in range(1,5):
  km = KMeans(n_clusters=i).fit(X)
  clusters.append(km.inertia_)
```

```
# membuat plot inertia
fig, ax = plt.subplots(figsize=(8, 4))
sns.lineplot(x=list(range(1, 5)), y=clusters, ax=ax)
ax.set_title('Cari Elbow')
ax.set_xlabel('Clusters')
ax.set_ylabel('Inertia')
```

```
# membuat objek KMeans
km2 = KMeans(n_clusters=2).fit(X)

# menambahkan kolom label pada dataset
X['Labels'] = km2.labels_

# membuat plot KMeans dengan 2 klaster
plt.figure(figsize=(8,4))

sns.scatterplot(
    x=X['nilai_akademik'],
    y=X['kehadiran'],
    hue=X['Labels'],
    palette=sns.color_palette('hls', 2)
)
```

```
plt.title('KMeans dengan 2 Cluster')
plt.show()
```

Tugas Praktikum : Mulai dengan studi kasus: segmentasi pelanggan mall

"Bayangkan kalian adalah seorang manajer mall. Kalian memiliki 200 data pelanggan. Setiap pelanggan memiliki informasi usia, pendapatan tahunan, dan skor belanja. Sebagai manajer, kalian ingin mengetahui karakteristik pelanggan agar dapat membuat strategi pemasaran yang tepat."

Contohnya:

- Pelanggan dengan pendapatan tinggi dan pengeluaran tinggi mungkin cocok mendapatkan program pelanggan VIP.
- Pelanggan dengan pendapatan tinggi tetapi pengeluaran rendah mungkin membutuhkan promosi khusus.
- Pelanggan dengan pendapatan rendah dan pengeluaran tinggi mungkin memiliki perilaku belanja yang berbeda.

1. Pertanyaannya: bagaimana mengelompokkan 200 pelanggan tersebut secara otomatis menggunakan K-Means? Link dataset: https://intip.in/kdateset
2. Hasil dan Laporan Praktikum diupload pada SLearn

e. Hasil dan Pembahasan

1. Dokumentasi Tugas berupa laporan praktikum (definisi, studi kasus tentang masing-masing clustering)
2. Dokumentasi Tugas berupa file ppt

f. Kesimpulan

Mahasiswa mampu menjelaskan clustering menggunakan k-means, memahami clustering dan menyelesaikan studi kasus latihan soal clustering.

g. Rubrik Penilaian

No	Indikator	Skor*			
1	Ketepatan waktu dan ketepatan dalam menjelaskan dari tugas ditunjang dengan bukti referensi	25	50	75	100

2	Ketepatan waktu dan ketepatan dalam menjelaskan dari tugas	25	50	75	100
3	Ketepatan waktu akan tetapi kurang tepat dalam menjelaskan tugas	25	50	75	100
4	Keterlambatan pengumpulan tugas dan ketidaktepatan dalam menjelaskan tugas	25	50	75	100
Jumlah skor					